SYNTHÈSE FINALE – Analyse Chlordécone (Notebook R)

Objectif

Analyser les données de contamination à la chlordécone en Martinique afin de :

- comprendre la distribution des concentrations
- identifier les zones à risque
- analyser l'influence des sols, de la topographie et de l'historique agricole
- produire des éléments utiles pour la décision publique

1. Qualité et structure des données

Après importation correcte :

- **31 126 observations**
- **27 variables**
- Variables principales :
  - Taux de chlordécone
  - Historique bananier (1970, 1980, 1992)
  - Topographie (TPI, TRI, rugosité, ombrage, exposition, pente)
  - Coordonnées X/Y
  - Informations de sol et de commune

Nettoyage effectué :

- Normalisation des noms (`clean_names`)
- Conversion des dates
- Conversion des variables numériques (remplacement virgules → points)
- Imputation robuste via **missForest**
- Suppression des doublons

2. Analyse exploratoire

📊 Distribution des variables numériques

Les boxplots montrent :

- une forte variabilité des variables historiques bananières
- des valeurs extrêmes dans les variables topographiques
- une distribution très étendue des années et des indices bananiers

📏 Distance de Mahalanobis

- Permet d'identifier des **observations atypiques**

- Plusieurs points dépassent le seuil du χ^2 → **présence d'outliers**

3. Analyse multivariée

ACP (Analyse en Composantes Principales)

- **Dim1 = 40,6 % de variance expliquée**
- **Dim2 = 22,5 %**
- Les variables topographiques contribuent fortement à Dim1
- Les variables historiques (banane 1970/1980/1992) influencent Dim2

Interprétation :

- Les parcelles se regroupent selon **la topographie** et **l'historique agricole**
- Les zones historiquement bananières sont clairement séparées dans l'espace factoriel

4. Analyse Factorielle de Données Mixtes (FAMD)

- Combine variables quantitatives + qualitatives
- Les communes, types de sols et historiques bananiers structurent fortement les individus
- Les parcelles se regroupent selon :
  - **type de sol**
  - **commune**
  - **historique bananier**

5. Clustering

CAH (Ward)

- Découpage en **4 groupes**
- Groupes cohérents avec :
  - topographie
  - historique bananier
  - localisation géographique

K-means (k = 4)

- Confirme la structure observée en CAH
- Un cluster regroupe les parcelles :
  - historiquement bananières
  - topographiquement favorables à l'accumulation
  - souvent associées à des taux plus élevés

6. Analyse spatiale

La carte X/Y colorée par taux montre :

- une **concentration des valeurs élevées dans certaines zones**
- cohérence avec les zones historiquement cultivées en banane
- cohérence avec les zones topographiquement plates ou humides

AIDE À LA DÉCISION – Recommandations

1. Prioriser les zones à risque

Les clusters identifiés et la carte spatiale montrent que certaines zones doivent être **prioritaires** :

- communes du Nord (Gros-Morne, Lorrain, Marigot, etc.)
- zones historiquement bananières
- zones topographiquement plates (accumulation)

2. Cibler les sols sensibles

Les sols **andosoliques** et **intergrades** retiennent davantage la chlordécone → ➡ **priorité pour la surveillance et les restrictions d'usage**

3. Renforcer la surveillance dans les zones à outliers

Les valeurs extrêmes détectées par Mahalanobis indiquent des parcelles nécessitant :

- re-prélèvements
- analyses complémentaires
- suivi renforcé

4. Utiliser les clusters pour optimiser les campagnes de prélèvements

Les clusters permettent de :

- réduire les coûts
- cibler les zones homogènes
- planifier les interventions

5. Intégrer la topographie dans les modèles prédictifs

La topographie explique une grande partie de la variance → ➡ utile pour prédire les zones à risque même sans prélèvement